inkor
inkorformacion.com

IFCT032PO
DATA MINING
BUSINESS INTELLIGENCE

23 mayo al 5 junio 2024

1. Como usar un **algoritmo** de "clustering simple", como ***K-Means***, para segmentar a los clientes en grupos basados en características similares.

Vamos a aplicar el **algoritmo K-Means** a los datos ficticios de clientes. Supongamos que queremos agrupar a los clientes en dos segmentos, usando la biblioteca scikit-learn:

```
from sklearn.cluster import Kmeans
import pandas as pd
import matplotlib.pyplot as plt

# Datos ficticios
data = {
    'Edad': [25, 30, 35, 40, 45],
    'Ingresos': [30000, 40000, 50000, 60000, 70000],
    'Compras_Anteriores': [5, 8, 3, 6, 10],
    'Monto_Gastado': [500, 800, 300, 600, 1000]
}

df = pd.DataFrame(data)


# Seleccionamos las características relevantes para la
segmentación
features = df[['Edad', 'Ingresos']]


# Aplicamos el algoritmo K-Means con… 2 clusters
kmeans = KMeans(n_clusters=2)
df['Cluster'] = kmeans.fit_predict(features)


# Visualizamos los resultados
plt.scatter(df['Edad'], df['Ingresos'], c=df['Cluster'],
cmap='viridis')
plt.title('Segmentación de clientes')
plt.xlabel('Edad')
plt.ylabel('Ingresos')
plt.show()
```

Este código utiliza el algoritmo K-Means para agrupar a los clientes en dos segmentos según su edad e ingresos. El **gráfico de dispersión** mostrará los puntos de datos coloreados según el cluster al que pertenecen.

El algoritmo y la forma de segmentar dependerán de los objetivos que planteés inicialmente y de la naturaleza y tipo de datos. K-Means es un ejemplo, y hay muchos otros algoritmos y librerías disponibles para la minería de datos, dependiendo de la naturaleza específica del problema.

Para mostrar en pantalla el resultado anterior: Asegúrate de tener instaladas las bibliotecas necesarias (pandas, scikit-learn, y matplotlib) antes de ejecutar el código.

PASOS:

- **Copia el anterior código en tu cuaderno de Kaggle:**

  Asegúrate de reemplazar 'tu-ruta-del-dataset' con la ruta correcta a tu conjunto de datos en Kaggle.

- **Ejecuta el cuaderno *Notebook*:**

  Haz clic en el botón **"Run All"** o ejecuta las celdas una por una para ver los resultados.

Además, puedes explorar otros algoritmos de clasificación en Kaggle para comparar su rendimiento.

En Kaggle, puedes utilizar bibliotecas de visualización de datos como *matplotlib* y *seaborn* para crear gráficos y visualizaciones. Sin embargo, ten en cuenta que en un entorno de cuaderno en línea como Kaggle, las gráficas generalmente se visualizan directamente en el cuaderno después de ejecutar el código.

BIBLIOTECAS:

- **matplotlib**: para crear gráficos y visualización de datos.
- **seaborn**: para crear gráficos y visualización de datos.
- **scikit-learn:** crea y entrena red neuronal o modelo de árbol de decisión.
- **pandas**: carga tus datos en un DataFrame.
- **folium**: crea mapas coropléticos y mapas interactivos..
- **geopandas**: para trabajar con datos geoespaciales.

LA ACTIVIDAD:

Pega a continuación el código que has eleborado: con la ruta de tus dataset y las primeras visualizaciones que te han salido. No preocuparse por los errores.

PON EL NOMBRE AL ARCHIVO PARA ENVIARMELO POR EL CHAT, ASI:

TuNombre_ACTIVIDAD_2.pdf