inkor
inkorformacion.com

IFCT032PO
DATA MINING
BUSINESS INTELLIGENCE

23 mayo al 5 junio 2024

Una **técnica descriptiva** común en minería de datos es el análisis de estadísticas descriptivas y la visualización de datos. Esto puede incluir la generación de: *A. resúmenes estadísticos, B. histogramas, y C. diagramas de dispersión y otros gráficos* para comprender mejor la distribución y las relaciones en los datos. Vamos a utilizar una técnica descriptiva simple con un conjunto de datos para calcular estadísticas resumidas y mostrar un histograma.

Supongamos que tenemos un conjunto de datos de clientes con las variables "Total_Compras" y "Meses_Activo", y queremos entender cómo se distribuyen estas variables. Aquí tienes un ejemplo de cómo podríamos hacerlo en Python utilizando las bibliotecas pandas y matplotlib:

```
import pandas as pd
import matplotlib.pyplot as plt

# Crear un conjunto de datos de clientes
clientes_data = {'Cliente': ['Cliente1', 'Cliente2', 'Cliente3', 'Cliente4',
'Cliente5', 'Cliente6', 'Cliente7'],
                 'Total_Compras': [1500, 200, 1000, 300, 150, 3800, 100],
                 'Meses_Activo': [12, 60, 24, 9, 38, 18, 3],
                 'Churn': [0, 1, 0, 1, 0, 1, 0]}


clientes_df = pd.DataFrame(clientes_data)


# A. Mostrar estadísticas descriptivas
print("Estadísticas descriptivas:")
print(clientes_df.describe())


# B. Mostrar histograma de Total_Compras
plt.hist(clientes_df['Total_Compras'], bins=20, color='blue', alpha=0.7)
plt.title('Histograma de Total_Compras')
plt.xlabel('Total_Compras')
plt.ylabel('Frecuencia')
plt.show()


# C. Mostrar diagrama de dispersión entre Total_Compras y Meses_Activo
plt.scatter(clientes_df['Total_Compras'], clientes_df['Meses_Activo'],
color='green', alpha=0.7)
plt.title('Diagrama de dispersión entre Total_Compras y Meses_Activo')
plt.xlabel('Total_Compras')
plt.ylabel('Meses_Activo')
plt.show()
```

A. Estadísticas descriptivas:

En este ejemplo, **clientes_df.describe()** proporciona estadísticas descriptivas como la media, la desviación estándar, los valores mínimo y máximo, etc:

```
                Total_Compras  Meses_Activo     Churn

count                7.
000000               7.000000  7.000000
mean             1007.142857     23.428571  0.428571
std              1338.664935     19.730325  0.534522
min               100.000000      3.000000  0.000000
25%               175.000000     10.500000  0.000000
50%               300.000000     18.000000  0.000000
75%              1250.000000     31.000000  1.000000
max              3800.000000     60.000000  1.000000
```

El **histograma** muestra cómo se distribuyen los valores en la variable "Total_Compras" y **el diagrama de dispersión** saca la relación entre "Total_Compras" y "Meses_Activo":

B. Histograma:

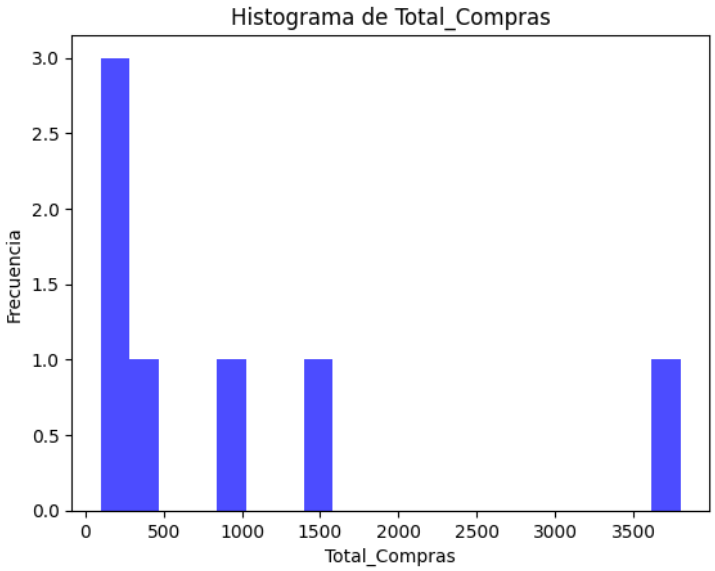

C. Diagrama de dispersión:

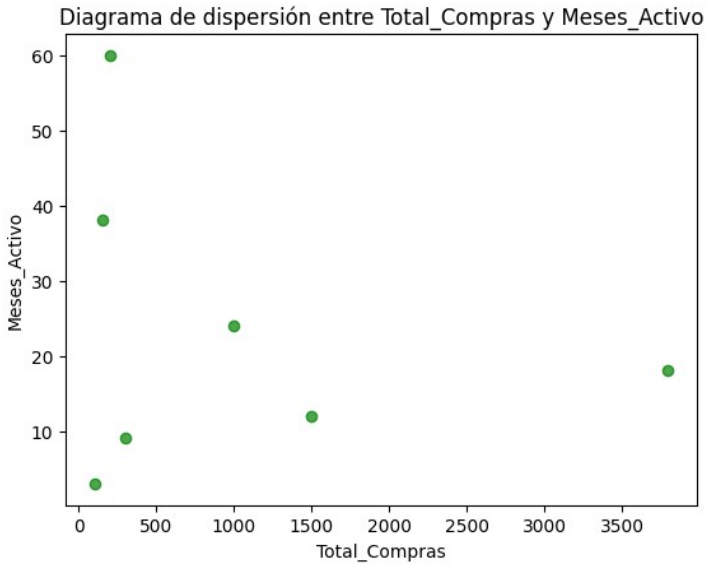

Estas visualizaciones y estadísticas ayudarán a obtener una comprensión más profunda de la estructura de tus datos.

LA ACTIVIDAD:

Mediante un código (se puede copiar) en Kaggle y con tu dataset propio **genera: un histograma y un diagrama de dispersión y pega a continuación**: el código y las dos visualizaciones que obtengas.

PON TU NOMBRE AL ARCHIVO PARA ENVIARMELO POR EL CHAT, ASI:
TuNombre-Apellidos_ACTIVIDAD 3.pdf