inkor
inkorformacion.com

IFCT032PO
DATA MINING
BUSINESS INTELLIGENCE

23 mayo al 5 junio 2024

SAN SEBASTIÁN · MADRID · BARCELONA · VALENCIA · MÁLAGA · PAMPLONA · LOGROÑO · QUERÉTARO (MX)

DATABASES

3 opciones

A. Conjunto de datos **ficticio**, *en base de datos:*

Cliente	Edad	Ingresos	Compras Anteriores	Monto Gastado
Cliente1	25	30000	5	5000
Cliente2	30	40000	8	8000
Cliente3	35	50000	3	3000
Cliente4	40	60000	6	600
Cliente5	45	70000	10	10000

Esta se puede exportar a .csv

Ejemplo:

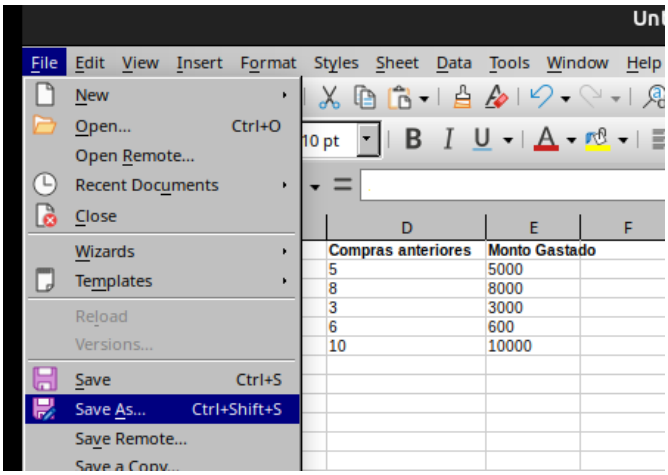

Esta base de datos o dataset se copia y pega o se crea en una hoja de calculo tipo excell.

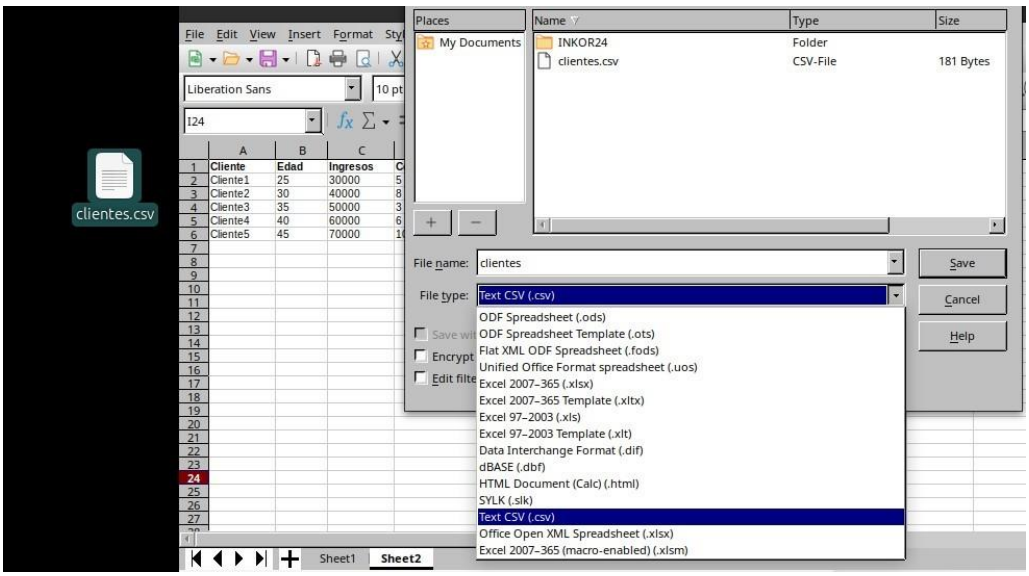

Se guarda como, (en File, Save As..) con extensión: CSV. Hecho;)

Otra opción de incluir la base datos, para hacerlo en código:

B. Mismo conjunto de datos ficticio, *en código Python:*

Se hace nombrando el df, signo igual (=) para dar el valor, de lo que está etre llaves ({}), que serán todos los campos siguientes.

Dentro de estas llaves: Nombre del campo (entre comillas simples ‘’, seguido de dos puntos (:) y los valores de ese campo separados por comas (,) y todos entre corchetes ([]).

Cada campo separado por comas (,).

```
import pandas as pd
from sklearn.cluster import Kmeans  ← bibliotecas...
import matplotlib.pyplot as plt

# Datos ficticios (este comentario no sale:)

data = {
'Edad': [25, 30, 35, 40, 45],
'Ingresos': [30000, 40000, 50000, 60000, 70000],
'Compras_Anteriores': [5, 8, 3, 6, 10],
'Monto_Gastado': [500, 800, 300, 600, 1000]
}

data2 = {
'Otros': [1, 2, 3, 4, 5, 6],
}

df = pd.DataFrame(data)
```

Explicación de cada cosa (por colores;)

- data es el nombre de esta base de datos ficticios, para llamarla de alguna manera, no? porque podía haber dos o más (como *data2*, *ejemplo de otro dataset*).
- debajo df (*dataframe*) llama a los datos de esta base de datos, *por su nombre* (variable data) y así coge sus valores.

--> *Lo mismo pero con otro nombre (la “variable”) y su valor (sus datos):*

```
clientes = {
'la , la , la ': [do ,re ,mi, fa, sol],
}
df = pd.DataFrame(clientes)
```

(Encima “se declara” y debajo se puede “invocar” para usarla).

C. Las dos opciones anteriores *(en una sola;)*:

- Además en algunos programas se pueden insertar nuestros dataset en csv. *Crea el tuyo más abajo;)*
- Otros dejan pegar la base de datos, tal cual o por medio del código, por simplificarnos la vida (RAW)..
- Los hay que tienen sus propios repositorios de bases de datos o desde fuentes públicas y solo hay que saber *redireccionarlos*, con y desde el código anterior para poder usar después las bibliotecas.. por ejemplo en *kaggle*:

```
# Conjunto de datos
df = pd.read_csv('kaggle/input/tu-ruta-del-dataset/clientes_dataset.csv')
```

Reemplaza "tu-ruta-del-dataset'/ y nombre csv: clientes_dataset.csv
(del sitio del programa donde lo has subido copia nombre y ruta, por ejemplo creando un nuevo Notebook y subiendo ahi tu Dataset en el programa;)

RECAPITULANDO:

```
import pandas as pd
from sklearn.cluster import Kmeans        ← bibliotecas ok
import matplotlib.pyplot as plt


# Conjunto de datos
   df =
pd.read_csv('kaggle/input/tu-ruta-del-dataset/clientes_dataset.csv')

# la Magia empieza pronto.....
```

Ahora con las bibliotecas instaladas, y llamando a la base de datos (o bien en .csv que hemos subido al programa) o bien insertada con sus valores en el código (como el primer ejemplo) se puede empezar a usar sus datos para pasar a la siguiente fase de con estos ejemplos:

https://matplotlib.org/stable/gallery/index.html

TU BASE DE DATOS:

1. Ahora la actividad consiste en que representes de las diferentes maneras vistas una base de datos propia, elaborada en cualquier hoja de calculo o descargada de los repositorios de internet públicos o de los programas, como Kaggle. Pega aquí tu base de datos:

2. Pega a continuación o modifica el ejemplo, tu propio dataset elaborando el código con tu base datos anterior, así:

```
# Completa el dataset:

NombreDB = {

      aquí tu base datos

}

df = pd.DataFrame(NombreDB)
```

3. Exporta el archivo de la base datos y guardalo en tu equipo (poniendo tu *nombre_al_archivo.csv*) para comprobar que coincide:

- lo que sale dentro de la base de datos de tu archivo (ACT.1)
- con la dataset que te marques con el código (ACT.2).

ARCHIVO CVS

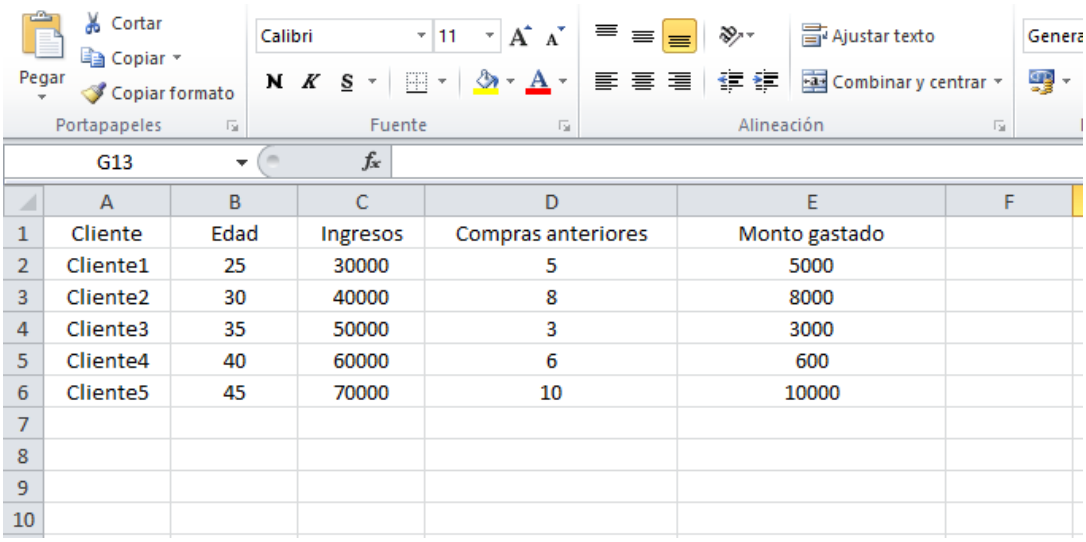

	A	B	C	D	E	F
1	Cliente	Edad	Ingresos	Compras anteriores	Monto gastado	
2	Cliente1	25	30000	5	5000	
3	Cliente2	30	40000	8	8000	
4	Cliente3	35	50000	3	3000	
5	Cliente4	40	60000	6	600	
6	Cliente5	45	70000	10	10000	
7						
8						
9						
10						

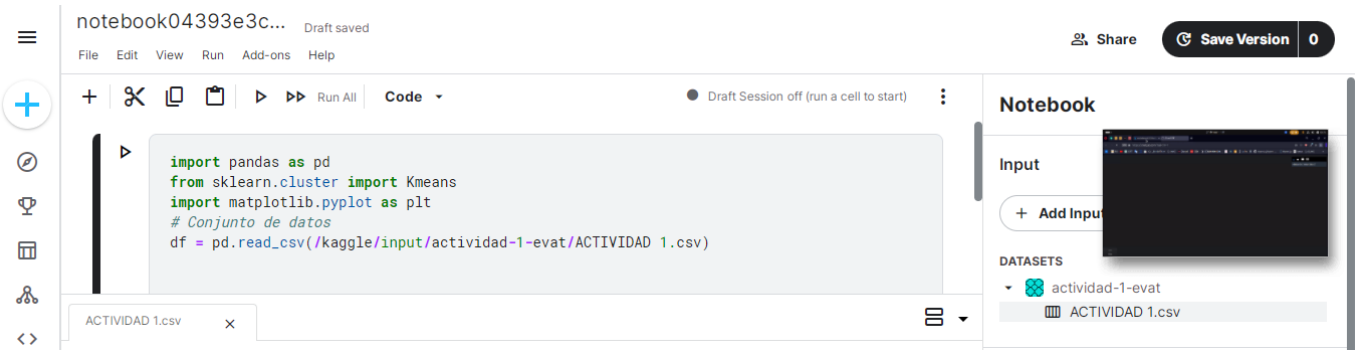

Notebook Draft | ACTIVIDAD 1.csv

ACTIVIDAD 1.csv (182 B) /kaggle/input/actividad-1-evat/ACTIVIDAD 1.csv

Cliente	Edad	Ingresos	Compras a...	Monto gas...
Cliente1	25	30000	5	5000
Cliente2	30	40000	8	8000
Cliente3	35	50000	3	3000
Cliente4	40	60000	6	600
Cliente5	45	70000	10	10000

No more data to show

Pon el nombre también a esta actividad para presentar:

TuNombre_ACTIVIDAD_1.pdf