MÓDULO 3:

Aprendizaje Automático (Machine Learning)

INTELIGENCIA ARTIFICIAL APLICADA A LA EMPRESA

Tabla de Contenido

Introducción 3

Objetivos 4

Tema 1. Fundamentos del aprendizaje automático 5

1.1 ¿Qué es el Machine Learning? 5

1.2 Flujo de trabajo en ML 12

1.3 Tipos de aprendizaje: supervisado, no supervisado y por refuerzo 20

Tema 2. Modelos supervisados 25

2.1 Clasificación vs regresión 25

2.2 Algoritmos: Árboles de decisión, Regresión logística, SVM, k-NN 29

Tema 3. Modelos no supervisados 36

3.1 Agrupamiento (clustering) 36

3.2 Algoritmos: K-means, DBSCAN, PCA 40

Resumen 46

Introducción

El **aprendizaje automático** representa uno de los pilares más relevantes y transformadores dentro del campo de la inteligencia artificial aplicada a la empresa. Este enfoque permite que los sistemas informáticos **aprendan de los datos, identifiquen patrones y tomen decisiones** sin necesidad de ser programados explícitamente para cada tarea específica.

Gracias a ello, las organizaciones pueden automatizar procesos, predecir comportamientos y optimizar recursos de manera eficiente, lo que se traduce en ventajas competitivas claras en un entorno cada vez más orientado a los datos.

En el contexto empresarial, el aprendizaje automático se aplica a un amplio abanico de funciones: desde la predicción de la demanda y el mantenimiento preventivo, hasta la segmentación de clientes y la detección de fraudes.

Su relevancia radica en su **capacidad para adaptarse y mejorar continuamente** conforme se alimenta de nuevos datos, lo que lo convierte en una herramienta esencial para la toma de decisiones estratégicas basada en evidencia empírica.

Este módulo proporciona una visión integral de los fundamentos del aprendizaje automático y sus principales modelos. Se abordan tanto técnicas supervisadas como no supervisadas, y se presentan algoritmos clave que todo profesional del ámbito empresarial y tecnológico debe conocer para liderar proyectos de innovación basados en datos.

Objetivos

A continuación, se presentan los objetivos principales de este módulo, que permitirán al participante adquirir una base sólida en aprendizaje automático:

- **Conocer** los conceptos fundamentales del aprendizaje automático y su importancia dentro de la inteligencia artificial.
- **Aprender a** distinguir entre los distintos tipos de aprendizaje: supervisado, no supervisado y por refuerzo.
- **Definir** los principales algoritmos utilizados en tareas de clasificación, regresión y agrupamiento.
- **Aplicar** modelos de aprendizaje automático a casos reales de negocio, interpretando sus resultados y evaluando su rendimiento.

Tema 1. Fundamentos del aprendizaje automático

El aprendizaje automático permite que los sistemas informáticos extraigan conocimiento a partir de los datos y mejoren su desempeño de manera progresiva.

Este enfoque resulta especialmente valioso en contextos donde existen **grandes volúmenes de información** y patrones complejos que no pueden ser abordados con reglas estáticas. Su aplicación ha revolucionado diversos sectores empresariales al facilitar la automatización de decisiones, el análisis predictivo y la adaptabilidad de los procesos.

A través del estudio de los principios que rigen esta disciplina, se abre la posibilidad de comprender cómo las máquinas pueden aprender de la experiencia, ajustar su comportamiento y ofrecer respuestas cada vez más precisas a problemas específicos. Esta capacidad tiene un impacto directo en la mejora continua de productos y servicios empresariales.

1.1 ¿Qué es el Machine Learning?

El **aprendizaje automático**, conocido internacionalmente como machine learning, es una rama destacada de la inteligencia artificial que se centra en dotar a los sistemas de la capacidad de aprender a partir de los datos.

A diferencia de los sistemas tradicionales, en los que el comportamiento se basa en reglas preprogramadas, en el aprendizaje automático los **algoritmos descubren patrones y relaciones en los datos**, mejorando su rendimiento conforme se exponen a nuevas informaciones.

Esta característica ha hecho que su aplicación sea decisiva en entornos empresariales que buscan una mayor eficiencia, precisión y rapidez en la toma de decisiones.

1.1.1 Fundamentos del aprendizaje automático

Para comprender con claridad el aprendizaje automático, es importante partir de su elemento más distintivo: la **capacidad de generalización**.

Un modelo entrenado correctamente no memoriza datos, sino que aprende patrones subyacentes que le permiten hacer predicciones o clasificaciones sobre datos nuevos. Este proceso se basa en una fase de entrenamiento, donde el sistema analiza ejemplos históricos, y una fase de prueba, en la que se valida su rendimiento ante casos que no había visto previamente.

Una característica muy importante del aprendizaje automático es que **necesita de datos para aprender**. Cuanto más extensos y representativos sean estos, mejores serán los resultados del modelo. Sin embargo, no solo la cantidad importa, también lo hace la calidad, la diversidad y la actualidad de la información proporcionada.

Además, para que los modelos sean eficientes, requieren de un **proceso riguroso de limpieza, transformación y selección de variables**, lo que se conoce como ingeniería de atributos. Este trabajo previo, aunque no visible en el resultado final, representa una parte determinante del éxito de cualquier proyecto de machine learning.

Asociado a este proceso también está la selección del modelo. No todos los algoritmos se comportan igual ante los mismos tipos de datos. Un **modelo lineal** puede ser adecuado para relaciones simples, mientras que las **redes neuronales profundas o los algoritmos de ensamblado** como Random Forest resultan más eficaces ante relaciones complejas.

Esta elección debe estar alineada con los objetivos del proyecto, la disponibilidad computacional y la interpretabilidad deseada.

1.1.2 Tipos principales de aprendizaje automático

El aprendizaje automático se puede clasificar en tres grandes grupos: **supervisado, no supervisado y por refuerzo**.

- El **primero** se basa en datos etiquetados, es decir, aquellos en los que se conoce de antemano la respuesta correcta. Esto permite entrenar modelos que, por ejemplo, clasifiquen correos como spam o no spam.
- El **segundo** grupo trabaja con datos sin etiquetar, ideal para descubrir segmentos de clientes o patrones de consumo.
- El **tercero**, el aprendizaje por refuerzo, consiste en entrenar agentes para tomar decisiones secuenciales mediante recompensas o penalizaciones obtenidas por sus acciones.

En el **aprendizaje supervisado**, los algoritmos más comunes son los árboles de decisión, la regresión logística y las máquinas de vectores de soporte. Estos modelos se utilizan ampliamente en sectores como las finanzas y la sanidad. Por ejemplo, se emplean para predecir la probabilidad de impago de un crédito o diagnosticar enfermedades a partir de síntomas.

El **aprendizaje no supervisado** se apoya en técnicas como el clustering (agrupamiento) o el análisis de componentes principales (PCA). Estas herramientas ayudan a segmentar clientes en grupos con comportamientos similares o a reducir la dimensionalidad de los datos para visualizarlos mejor.

Las empresas de telecomunicaciones suelen utilizar estos métodos para identificar grupos de usuarios con patrones de consumo de datos similares y ofrecerles planes personalizados.

Por su parte, el **aprendizaje por refuerzo** está ganando popularidad gracias a los avances en robótica y videojuegos. En este caso, el sistema aprende mediante la interacción continua con su entorno, recibiendo retroalimentación para mejorar sus decisiones. Es el tipo de aprendizaje usado en los coches autónomos para tomar decisiones sobre la marcha, considerando miles de variables del entorno.

1.1.3 Ventajas del machine learning en la empresa

Las ventajas que aporta esta tecnología son diversas. En primer lugar, **la automatización de tareas repetitivas** permite liberar recursos humanos para actividades de mayor valor.

En segundo lugar, la **capacidad de anticipar tendencias** mediante modelos predictivos puede significar una mejora competitiva muy importante. Empresas como DHL utilizan modelos para prever retrasos en envíos y ajustar sus rutas logísticas en tiempo real.

Otra ventaja muy relevante es la **mejora de la experiencia del cliente**. Gracias al aprendizaje automático, se pueden analizar comentarios y opiniones en redes sociales o formularios, clasificarlos según su polaridad y derivar acciones que refuercen la satisfacción del usuario.

Asimismo, el machine learning favorece la **toma de decisiones** basada en datos objetivos, minimizando errores humanos y aportando argumentos sólidos para justificar acciones empresariales. Su aplicación también permite optimizar recursos, ajustar presupuestos y mejorar la eficiencia en el uso de materiales, tiempo y energía.

Un beneficio adicional es su **aplicación en la detección de anomalías**. En el ámbito de la ciberseguridad, los modelos aprenden el comportamiento

habitual de los usuarios y alertan cuando detectan desviaciones que podrían representar amenazas.

¿Sabías que?

El primer programa considerado como aprendizaje automático fue desarrollado por Arthur Samuel en 1959, quien diseñó un sistema capaz de aprender a jugar a las damas y mejorar con el tiempo. Esta aplicación es uno de los precedentes de los modernos algoritmos que hoy guían desde coches autónomos hasta asistentes virtuales.

1.1.4 Desafíos del aprendizaje automático

Aunque sus ventajas son numerosas, también existen retos a considerar. Uno de los principales es el **sesgo en los datos**. Si los datos de entrenamiento contienen prejuicios o están desbalanceados, el modelo aprenderá y reproducirá esas mismas distorsiones.

Esto puede tener consecuencias negativas en ámbitos como la selección de personal, donde un modelo sesgado podría discriminar sin que se note a simple vista.

Otro reto frecuente es la **interpretabilidad** de los modelos. Algunos algoritmos, como los basados en redes neuronales profundas, actúan como "cajas negras", dificultando la explicación de por qué se toma una determinada decisión.

Este aspecto es especialmente delicado en sectores regulados como la salud o las finanzas, donde las decisiones deben justificarse ante entidades regulatorias o clientes.

También se encuentra el **reto de la actualización constante**. Los modelos necesitan ser revisados y recalibrados de forma periódica, ya que los datos pueden evolucionar.

Si no se ajustan, pueden perder precisión y convertirse en una fuente de errores. Esta tarea requiere recursos, conocimiento técnico y procesos de validación rigurosos.

1.1.5 Tabla de clasificación y usos

A continuación, se presenta una tabla que resume de forma comparativa las características principales de los distintos tipos de aprendizaje automático.

Este recurso facilita la comprensión de sus diferencias, objetivos y aplicaciones prácticas más comunes en entornos reales, permitiendo identificar con mayor claridad cuál es el estilo más adecuado según el tipo de problema y los datos disponibles.

Tipo de aprendizaje	Características clave	Ejemplos de uso
Supervisado	Datos con etiquetas conocidas	Clasificación de correos, detección de fraude
No supervisado	Datos sin etiquetas, búsqueda de patrones	Segmentación de clientes, análisis exploratorio
Por refuerzo	Agente aprende mediante ensayo y error con recompensas	Juegos, robótica, sistemas de recomendación

Tabla 1: Comparativa de tipos de aprendizaje automático

¿Sabías que?

Google utiliza algoritmos de aprendizaje automático para optimizar el consumo de energía en sus centros de datos. Gracias a ello ha conseguido reducir el uso energético en un 40%, un ahorro muy significativo tanto en términos económicos como medioambientales.

1.2 Flujo de trabajo en ML

El desarrollo de un proyecto de **aprendizaje automático** conlleva un conjunto de pasos organizados que permiten transformar datos brutos en modelos predictivos capaces de generar valor.

Este itinerario técnico, conocido como **flujo de trabajo en machine learning**, es una guía que proporciona estructura y coherencia a los equipos de ciencia de datos, facilitando la implementación efectiva de soluciones.

Cada etapa del proceso requiere habilidades específicas, metodologías y decisiones estratégicas para alcanzar resultados óptimos.

1.2.1 Definición del problema y objetivos del proyecto

El primer paso en cualquier flujo de trabajo consiste en **definir con claridad el problema** que se desea resolver. Esta tarea no debe realizarse desde una óptica puramente técnica, sino en diálogo con las necesidades reales del negocio.

Una **formulación precisa del objetivo** permite seleccionar las técnicas y datos más adecuados. Es decisivo saber si se trata de un problema de

clasificación, regresión o agrupamiento, ya que cada uno requiere un tratamiento específico.

Un ejemplo práctico lo encontramos en el sector de la moda, donde una empresa como Zalando podría plantearse predecir la probabilidad de devolución de una prenda según el perfil del comprador. Este planteamiento delimita el problema y orienta las decisiones posteriores del flujo.

1.2.2 Recolección y exploración de los datos

Una vez definido el problema, el siguiente paso consiste en **recolectar los datos pertinentes**. Esto puede implicar el acceso a bases internas como CRMs, ERPs o bases de transacciones, así como la integración de fuentes externas. Es prioritario garantizar que los **datos son relevantes, completos y representativos** del fenómeno que se quiere modelar.

La exploración inicial, o **exploratory data analysis**, permite identificar patrones, correlaciones y posibles anomalías. En este momento se realizan visualizaciones básicas y se calculan estadísticas descriptivas para comprender mejor la estructura de los datos.

Por ejemplo, un hospital como el Gregorio Marañón podría analizar historiales clínicos para encontrar relaciones entre factores de riesgo y diagnósticos.

1.2.3 Preparación y transformación de datos

Esta fase es una de las más exigentes y determinantes del proceso. Incluye tareas como **la imputación de valores faltantes, la normalización de variables numéricas, la codificación de variables categóricas y la detección de outliers**. La calidad de esta preparación tiene un impacto directo sobre el rendimiento del modelo.

Por ejemplo, una cadena de supermercados como Mercadona podría transformar las variables de ventas mensuales para detectar estacionalidades antes de construir un modelo de predicción de demanda.

Aquí también se seleccionan las variables que aportan mayor información, reduciendo la dimensionalidad del problema y evitando el sobreajuste.

1.2.4 Selección del modelo y técnica de aprendizaje

Con los datos preparados, el equipo debe **elegir el algoritmo** que mejor se adapte al objetivo planteado. Para tareas de clasificación se suelen emplear árboles de decisión, Random Forest o SVM, mientras que para regresión se puede optar por regresión lineal, XGBoost o redes neuronales.

La selección no depende solo del tipo de problema, sino también de la interpretabilidad deseada, los recursos computacionales disponibles y la cantidad de datos.

Por ejemplo, ING utiliza modelos interpretables en sus procesos crediticios para justificar ante los reguladores las decisiones automáticas tomadas.

1.2.5 Entrenamiento y evaluación del modelo

En esta etapa se **dividen los datos** en conjuntos de **entrenamiento y prueba**, y en algunos casos se añade un conjunto de validación. El modelo se ajusta sobre el primer subconjunto, y su rendimiento se evalúa con los otros, utilizando métricas específicas como la precisión, la exactitud o el área bajo la curva ROC.

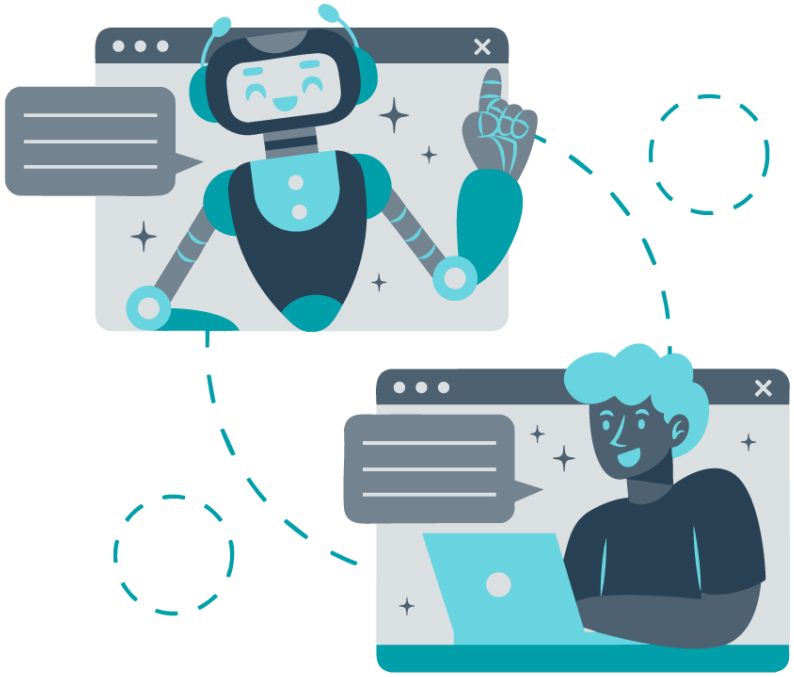

Un modelo de predicción de rotación de empleados en una empresa tecnológica como Indra podría evaluar su calidad en función de la capacidad para distinguir correctamente entre empleados que se quedan y los que se marchan. En esta fase también se realiza ajuste de hiperparámetros y pruebas cruzadas para garantizar la robustez del modelo.

1.2.6 Interpretación y validación de resultados

Tras el entrenamiento, es necesario **interpretar el comportamiento del modelo** para asegurar que tiene sentido desde el punto de vista del negocio. Esto implica analizar la importancia de las variables, detectar

posibles errores sistemáticos y validar que los resultados son coherentes con la experiencia previa.

Empresas como Repsol han aplicado esta fase en proyectos de exploración geológica para asegurar que las predicciones se ajustaban a los criterios técnicos de los geólogos, evitando errores que podrían traducirse en inversiones millonarias mal dirigidas.

1.2.7 Implementación y puesta en producción

Una vez validado, el modelo se implementa en un entorno productivo. Esto puede requerir convertirlo en una API (Application Programming Interface), integrarlo en una aplicación o conectarlo a una base de datos que alimente nuevos datos en tiempo real.

La **robustez y escalabilidad** son claves para asegurar el correcto funcionamiento en condiciones reales.

Un ejemplo puede verse en el sector de los seguros, donde Mapfre ha desplegado modelos que, integrados con su sistema de atención al cliente, ofrecen recomendaciones automáticas para ajustar primas según el perfil de riesgo actualizado del asegurado.

1.2.8 Monitorización y mantenimiento del modelo

El trabajo no termina al poner el modelo en producción. Es imprescindible monitorizar su comportamiento a lo largo del tiempo para detectar desviaciones, degradaciones o cambios en los patrones de datos. Esta monitorización permite lanzar retrainings cuando sea necesario y actualizar las variables si cambian las condiciones del entorno.

En el sector bancario, Caixabank monitoriza sus modelos de predicción de fraude cada semana para asegurar que continúan siendo eficaces ante nuevas técnicas de estafa. Esta tarea evita que los modelos pierdan valor con el tiempo.

1.2.9 Tabla Resumen: Etapas del flujo de trabajo en ML

La siguiente tabla ofrece una visión estructurada de las principales etapas que conforman el flujo de trabajo en un proyecto de aprendizaje automático.

Cada fase se describe junto con su propósito clave y un ejemplo ilustrativo que ayuda a contextualizar su aplicación en entornos empresariales reales.

Este esquema sirve como guía práctica para comprender el recorrido completo desde la formulación del problema hasta la monitorización del modelo en producción.

Etapa	Objetivo principal	Ejemplo práctico
Definición del problema	Identificar el tipo de tarea y necesidades del negocio	Predecir devoluciones en e-commerce
Recolección de datos	Reunir información de distintas fuentes	CRMs, sensores, redes sociales
Preparación de datos	Limpiar, transformar y seleccionar variables	Normalización, codificación, filtrado
Selección del modelo	Escoger algoritmo adecuado según objetivo y datos	SVM, Random Forest, XGBoost
Entrenamiento y evaluación	Ajustar parámetros y medir el rendimiento del modelo	Validación cruzada, matriz de confusión
Interpretación y validación	Verificar coherencia y valor de las predicciones	Importancia de variables, errores
Implementación	Integrar el modelo en procesos reales	API, dashboards, aplicaciones
Monitorización	Asegurar el rendimiento del modelo con el paso del tiempo	Alertas, retrainings, logs

Tabla 2: Etapas del flujo de trabajo en ML

1.3 Tipos de aprendizaje: supervisado, no supervisado y por refuerzo

El aprendizaje automático se estructura en tres grandes paradigmas que responden a diferentes necesidades, fuentes de datos y estrategias de resolución de problemas.

Estos estilos son el **aprendizaje supervisado**, el **aprendizaje no supervisado** y el **aprendizaje por refuerzo**. Cada uno presenta un conjunto de algoritmos, métodos de entrenamiento y usos específicos, lo que los convierte en herramientas versátiles dentro del repertorio de la inteligencia artificial moderna.

Figura 1. Tipos de Aprendizaje Automático

1.3.1 Aprendizaje supervisado: predicción con datos etiquetados

En este tipo de aprendizaje, el modelo se entrena a partir de un conjunto de datos donde **cada entrada está emparejada con una etiqueta o resultado** esperado.

El **objetivo** es aprender una función que, **dados nuevos datos, pueda predecir la salida correcta** con alta precisión. Es el paradigma más extendido y utilizado en tareas de **clasificación y regresión**.

Un ejemplo concreto es la predicción de abandono de clientes en servicios de telefonía. Vodafone puede usar historiales de consumo, llamadas al centro de atención y datos demográficos para entrenar un modelo que clasifique si un cliente tiene alta o baja probabilidad de cancelar el contrato.

Las principales técnicas en este campo incluyen árboles de decisión, **máquinas de vectores de soporte** (SVM), redes neuronales y algoritmos de ensamblado como Random Forest y Gradient Boosting. Cada una ofrece

ventajas distintas en función del problema planteado y los datos disponibles.

1.3.2 Aprendizaje no supervisado: descubrimiento de patrones

A diferencia del supervisado, en este caso los datos no cuentan con etiquetas. El objetivo consiste en identificar estructuras internas, **patrones o agrupamientos** que permitan entender mejor la información o reducir su complejidad.

Este tipo de aprendizaje se emplea mucho en la exploración inicial de datos y en la generación de insights que no son evidentes a simple vista.

Por ejemplo, una plataforma de streaming como Spotify puede usar clustering para segmentar a sus usuarios según sus preferencias musicales, tiempos de reproducción y dispositivos utilizados. Estas agrupaciones permiten definir estrategias de marketing más afinadas.

Entre los algoritmos más representativos se encuentran K-means, DBSCAN, algoritmos jerárquicos y técnicas de reducción de dimensionalidad como PCA. Estos métodos son especialmente útiles en sectores como la investigación biomédica, el comercio electrónico o la ciberseguridad.

1.3.3 Aprendizaje por refuerzo: optimización mediante retroalimentación

En este planteamiento, un agente aprende a actuar dentro de un entorno mediante ensayo y error. Las decisiones del agente se ven recompensadas o penalizadas en función de los resultados obtenidos, y su objetivo es

maximizar la suma total de recompensas a lo largo del tiempo. Se trata de un aprendizaje secuencial y adaptativo.

Un ejemplo paradigmático lo representa DeepMind, la filial de Google, que logró que su sistema AlphaGo venciera a campeones humanos en el juego Go. También se emplea en vehículos autónomos, donde el agente debe aprender a mantener el control del coche en condiciones diversas y cambiantes.

Los algoritmos más habituales incluyen Q-learning, SARSA y variantes modernas como Deep Q Networks (DQN). Este tipo de aprendizaje requiere entornos de simulación o acceso constante a datos en tiempo real, por lo que su aplicación suele centrarse en ámbitos industriales, videojuegos o gestión de operaciones.

1.3.4 Comparativa de tipos de aprendizaje automático

A continuación, se presenta una tabla que resume las características clave de los principales tipos de aprendizaje automático. Esta comparación facilita la comprensión de sus diferencias en cuanto a necesidades de datos, objetivos, metodologías y aplicaciones prácticas.

Es un recurso útil para seleccionar la técnica más adecuada según el tipo de problema a abordar y la naturaleza de los datos disponibles.

Tipo de aprendizaje	Datos necesarios	Objetivo principal	Ejemplos de uso
Supervisado	Datos con etiquetas	Predecir o clasificar resultados conocidos	Diagnóstico médico, detección de fraude
No supervisado	Datos sin etiquetas	Descubrir patrones o estructuras ocultas	Segmentación de clientes, análisis exploratorio
Por refuerzo	Interacción con entorno	Aprender secuencias de decisiones óptimas	Control robótico, juegos, trading automatizado

Tabla 3: Comparativa de tipos de aprendizaje automático

¿Sabías que?

El algoritmo Q-learning, utilizado en el aprendizaje por refuerzo, se basa en teoría de juegos y ha sido aplicado para enseñar a drones a volar en entornos urbanos complejos evitando colisiones sin necesidad de GPS.

Tema 2. Modelos supervisados

Los modelos supervisados representan una de las formas más extendidas de aprendizaje automático en aplicaciones reales. Este enfoque parte de conjuntos de datos previamente etiquetados, donde cada entrada está asociada a una salida esperada.

A partir de esta información, el modelo aprende a establecer relaciones entre las variables, lo que permite hacer predicciones sobre datos nuevos con un alto grado de precisión.

Estos modelos son empleados en múltiples ámbitos empresariales, como la detección de fraudes, la predicción de ventas o la clasificación de clientes. Su valor radica en la capacidad de extraer conocimiento accionable de datos históricos, apoyando la toma de decisiones basadas en evidencias cuantitativas.

2.1 Clasificación vs regresión

Dentro del aprendizaje automático supervisado, las tareas que se pueden abordar se dividen en dos grandes grupos según la naturaleza de la variable objetivo: **clasificación** y **regresión**.

Aunque ambas comparten el mismo principio de entrenamiento a partir de datos etiquetados, difieren en el tipo de predicción que realizan, las técnicas que emplean y los sectores donde se aplican con mayor eficacia.

Comprender estas diferencias es indispensable para seleccionar el modelo adecuado en función del problema a resolver.

2.1.1 Clasificación: decidir entre categorías

La clasificación se refiere a problemas en los que la salida esperada pertenece a un conjunto finito de clases. El objetivo del modelo es aprender a asignar correctamente una etiqueta a cada instancia, basándose en los valores de sus variables de entrada. Esta tarea es común en situaciones donde se necesita tomar decisiones binarias o multinomiales.

Un ejemplo típico es la detección de correos electrónicos de tipo spam. El sistema analiza el contenido, el remitente y la estructura del mensaje para predecir si se trata de un correo deseado o no deseado. Este tipo de aplicación es ampliamente usado por servicios de correo como Gmail o Outlook.

Las técnicas de clasificación incluyen árboles de decisión, regresión logística, máquinas de vectores de soporte y redes neuronales. Una de sus características más valoradas es que permiten trabajar con problemas de dos clases o de múltiples clases sin modificar el planteamiento básico del modelo.

2.1.2 Regresión: estimar valores continuos

En el caso de la regresión, la variable objetivo es numérica y continua. El objetivo del modelo es encontrar una función que estime con la mayor precisión posible el valor de salida a partir de los datos de entrada. A

diferencia de la clasificación, aquí las predicciones no se limitan a clases discretas, sino que pueden tomar cualquier valor dentro de un rango.

Un caso práctico lo representa la predicción del precio de una vivienda. A partir de variables como la ubicación, metros cuadrados, número de habitaciones o antigüedad del inmueble, un modelo de regresión puede estimar su valor de mercado con gran precisión.

Las técnicas más comunes incluyen la regresión lineal, regresión por vecinos más cercanos (k-NN), regresión de Ridge o Lasso y modelos avanzados como XGBoost y redes neuronales profundas.

2.1.3 Diferencias clave entre clasificación y regresión

Aunque ambas tareas pertenecen al aprendizaje supervisado y comparten metodologías similares en cuanto a preparación de datos y validación de resultados, presentan diferencias claras en términos de aplicación, salida del modelo y métricas de evaluación.

En clasificación, el resultado es una categoría, mientras que en regresión es un número. Las métricas de clasificación incluyen la precisión, el recall, la F1-score y la matriz de confusión. Por su parte, la regresión se evalúa mediante el error cuadrático medio (MSE), el error absoluto medio (MAE) o el coeficiente de determinación R^2.

Criterio	Clasificación	Regresión
Tipo de salida	Clase o categoría discreta	Valor numérico continuo
Ejemplo de problema	Diagnóstico de enfermedad (sí/no)	Predicción de nivel de glucosa en sangre
Algoritmos frecuentes	Regresión logística, SVM, Random Forest	Regresión lineal, Ridge, Lasso, XGBoost
Métricas comunes	Precisión, recall, F1-score, matriz de confusión	MAE, MSE, R^2
Visualización del resultado	Gráficos de barras o matrices de confusión	Gráficas de dispersión, curvas de ajuste

Tabla 4: Diferencias entre clasificación y regresión

2.1.4 Ejemplos sectoriales

En el **ámbito bancario**, los modelos de clasificación se utilizan para predecir la morosidad de un cliente. La salida es binaria: pagará o no pagará. En cambio, un modelo de regresión puede emplearse para estimar el importe medio que un cliente solicitará como crédito personal.

En el **sector salud**, la clasificación permite detectar si una imagen radiológica contiene indicios de tumor o no. Por su parte, la regresión puede predecir la probabilidad estimada de supervivencia de un paciente según sus indicadores biomédicos.

En **marketing**, un modelo de clasificación predice si un cliente hará clic en una campaña. Mientras tanto, uno de regresión estima el importe total que gastará ese mismo cliente si realiza la compra.

¿Sabías que?

Netflix usa clasificación para sugerir si un usuario puede estar interesado en un contenido específico (sí o no) y emplea regresión para estimar la puntuación probable que ese mismo usuario asignará al contenido.

2.2 Algoritmos: Árboles de decisión, Regresión logística, SVM, k-NN

Los algoritmos de clasificación desempeñan un papel decisivo en el aprendizaje supervisado, ya que permiten asignar observaciones a diferentes categorías de forma automatizada.

Cada algoritmo tiene características específicas, ventajas particulares y casos de uso recomendados. A continuación, se presenta un análisis pedagógico de cuatro algoritmos ampliamente utilizados: **árboles de decisión**, **regresión logística**, **máquinas de vectores de soporte (SVM)** y **k-vecinos más cercanos (k-NN)**.

2.2.1 Árboles de decisión: interpretabilidad con estructura jerárquica

Los árboles de decisión funcionan mediante una división recursiva de los datos, creando nodos de decisión en función de las variables más discriminativas.

Cada nodo representa una condición, y cada rama un resultado que lleva a nuevas divisiones o a hojas finales con una clasificación concreta.

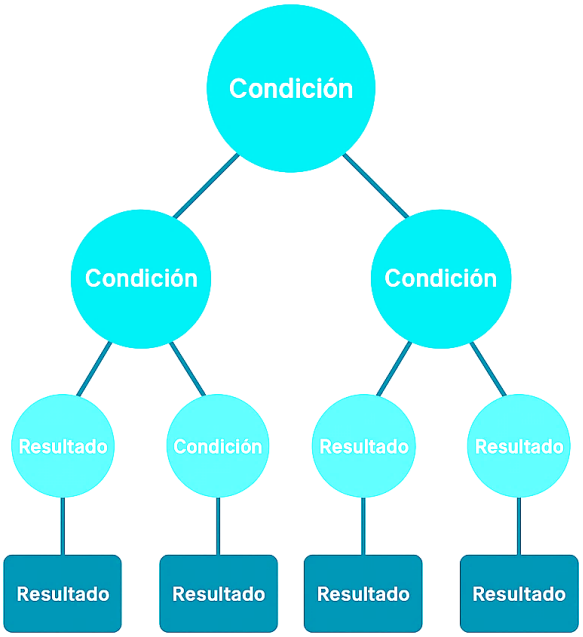

Figura 2: Árbol de decisión

Su principal ventaja es su alta interpretabilidad. Los usuarios pueden visualizar fácilmente el camino que lleva a una decisión, lo que los hace ideales para sectores donde se exige transparencia, como la salud o los servicios financieros.

Ejemplo:

Un banco como Santander puede utilizarlos para aprobar o rechazar créditos, mostrando de forma comprensible por qué se ha tomado una decisión.

Sin embargo, tienden a sobreajustar los datos si no se controlan adecuadamente. Por ello, se suele recurrir a algoritmos de ensamblado como Random Forest para mejorar su robustez.

2.2.2 Regresión logística: simplicidad con gran rendimiento binario

La regresión logística es una técnica estadística que estima la probabilidad de que una observación pertenezca a una clase determinada. Utiliza una función logística o sigmoide para mapear los valores de entrada a un rango entre 0 y 1.

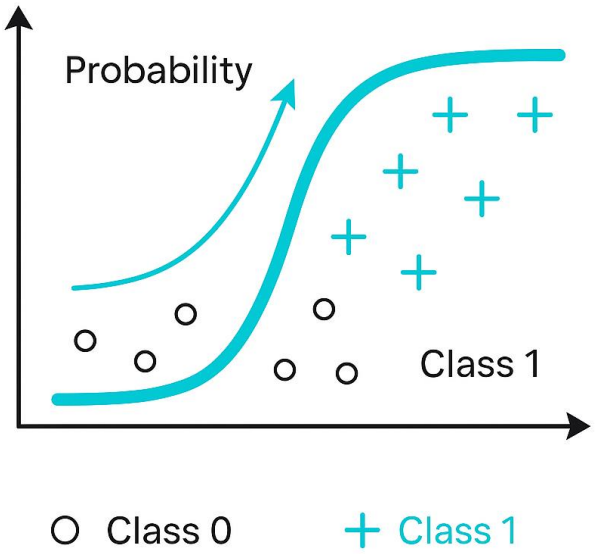

Figura 3: Regresión Logística

Este modelo es muy utilizado en problemas de clasificación binaria.

Por ejemplo, en una campaña de email marketing, una empresa como IKEA podría predecir si un usuario abrirá o no un correo en función de variables como el historial de compras o el tiempo de suscripción.

La regresión logística es menos propensa al sobreajuste si se aplican correctamente técnicas de regularización como L1 o L2. Además, ofrece resultados fácilmente interpretables mediante el análisis de coeficientes.

2.2.3 SVM (Support Vector Machine): clasificadores de frontera máxima

Las máquinas de vectores de soporte crean hipermedias que separan las clases con el mayor margen posible. La idea es encontrar el hiperplano que deja la mayor distancia entre los puntos de entrenamiento más cercanos de cada clase.

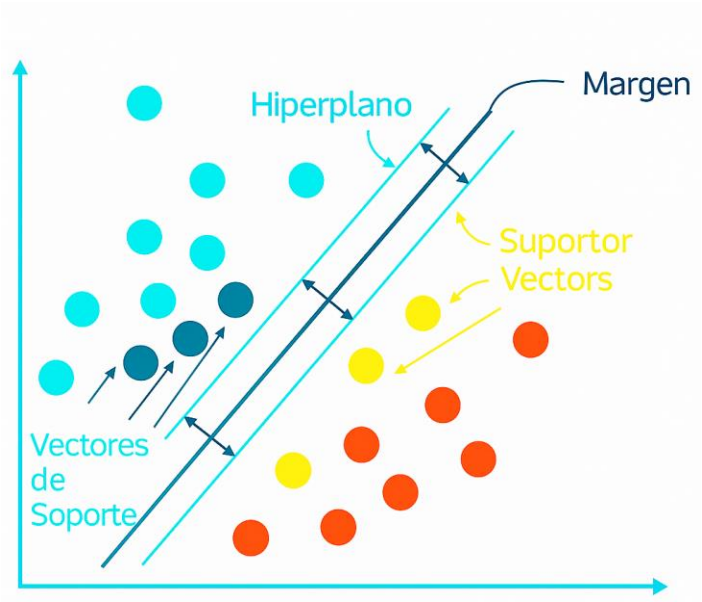

Figura 4: Máquina de Soporte Vectorial

Este algoritmo es especialmente útil cuando los datos no son linealmente separables, ya que utiliza técnicas de transformación como el *kernel trick* para proyectar los datos a espacios de mayor dimensionalidad donde se pueda realizar la separación.

Empresas de telecomunicaciones como Orange pueden aplicar SVM para identificar patrones de abandono de clientes en base a interacciones con el servicio, tipo de contrato y volumen de consumo.

SVM destaca por su capacidad de generalización y su eficacia en espacios de alta dimensionalidad, aunque su entrenamiento puede ser intensivo en recursos computacionales.

2.2.4 K-vecinos más cercanos (k-NN): clasificación por proximidad

El algoritmo k-NN es uno de los más intuitivos. Para clasificar una nueva instancia, se busca cuáles son sus k vecinos más cercanos en el espacio de características y se asigna la clase mayoritaria entre ellos. Este método no necesita entrenamiento, lo que simplifica su implementación.

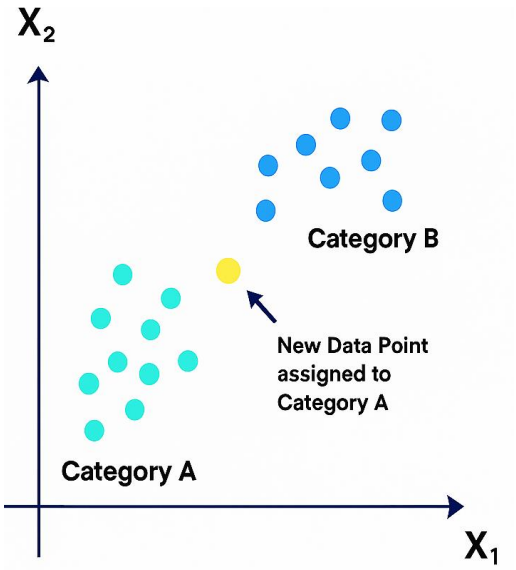

Figura 5: K-NN

Su rendimiento depende fuertemente de la elección del valor de k y de la forma en que se mide la distancia entre puntos. Se emplea en aplicaciones de reconocimiento de imágenes, detección de intrusiones en sistemas y recomendadores de contenido.

Un museo como el Prado podría utilizar k-NN para recomendar obras similares a las vistas por el visitante, basándose en el tiempo de permanencia y preferencias anteriores.

2.2.5 Comparativa de algoritmos de clasificación

La siguiente tabla presenta una comparativa estructurada entre algunos de los algoritmos de clasificación más utilizados en aprendizaje automático. Se analizan aspectos clave como sus principales ventajas, limitaciones y los contextos en los que se aplican con mayor frecuencia.

Esta síntesis permite comprender de forma clara y pedagógica cuál es el algoritmo más apropiado según la naturaleza del problema y los requisitos del proyecto.

Algoritmo	Ventajas principales	Limitaciones	Casos de uso frecuentes
Árboles de decisión	Interpretables, fáciles de visualizar	Sobreajuste si no se poda el árbol	Evaluación de crédito, diagnóstico médico
Regresión logística	Simples, eficientes, coeficientes interpretables	Solo para problemas lineales	Marketing por email, clasificación binaria
SVM	Potente en alta dimensionalidad, eficaz con pocos datos	Difícil de escalar en grandes volúmenes	Análisis de sentimientos, detección de abandono
k-NN	Intuitivo, sin fase de entrenamiento	Lento en predicción con grandes datasets	Sistemas de recomendación, reconocimiento visual

Tabla 5: Comparativa de algoritmos de clasificación

¿Sabías que?

El algoritmo SVM fue utilizado por primera vez a gran escala por Google en 2002 para clasificar páginas web como spam o contenido válido. Su precisión fue determinante para mejorar los resultados del buscador.

Tema 3. Modelos no supervisados

El aprendizaje no supervisado permite descubrir estructuras ocultas dentro de conjuntos de datos sin necesidad de etiquetas predefinidas. Esta metodología es **especialmente útil cuando se dispone de grandes volúmenes de información**, pero se carece de clasificaciones previas.

A través de técnicas como el **agrupamiento o la reducción de dimensionalidad**, es posible segmentar clientes, identificar patrones de comportamiento o simplificar la complejidad de los datos.

Este tipo de modelos abre nuevas posibilidades de análisis exploratorio, permitiendo que las empresas obtengan conocimiento no evidente de sus operaciones y usuarios. Su aplicación ofrece una base sólida para iniciativas de personalización, optimización de recursos y generación de estrategias más informadas.

3.1 Agrupamiento (clustering)

El **agrupamiento**, o *clustering*, es una técnica propia del aprendizaje automático no supervisado que tiene como objetivo **descubrir grupos ocultos dentro de los datos**.

A diferencia de los modelos supervisados, este estilo de análisis no parte de etiquetas conocidas, sino que se basa en la identificación de estructuras, patrones o relaciones naturales que puedan existir entre las observaciones.

Su aplicación resulta determinante en contextos donde se necesita explorar grandes volúmenes de información sin conocimientos previos, identificar tendencias o segmentar perfiles de usuarios o comportamientos.

El clustering permite **agrupar elementos similares entre sí y diferenciarlos de aquellos que presentan comportamientosnhnn distintos**. Esta capacidad se ha vuelto indispensable para mejorar la personalización en marketing, optimizar sistemas de recomendación, analizar fraudes financieros y realizar diagnósticos asistidos por máquina, entre otros usos.

3.1.1 Características del clustering

Uno de los elementos que distingue al clustering es que **no requiere información etiquetada** para funcionar.

El algoritmo actúa sobre un conjunto de datos intentando maximizar la similitud dentro de los grupos y minimizarla entre diferentes grupos. Esto se realiza a través de métricas de distancia como la euclídea, de Manhattan o coseno.

Otra característica relevante es su **adaptabilidad** a distintos tipos de datos, incluyendo variables numéricas, categóricas y mixtas. Este tipo de técnicas se complementa con representaciones visuales que facilitan el análisis, como mapas de calor, gráficos de dispersión tridimensionales y dendrogramas.

3.1.2 Algoritmos más comunes

Entre los algoritmos de clustering más utilizados se encuentran **K-means**, **DBSCAN** y los **algoritmos jerárquicos**. Cada uno presenta ventajas y limitaciones específicas, lo que los hace adecuados para diferentes contextos.

K-means parte de un número predefinido de clústeres y asigna los puntos a estos en función de su proximidad al centroide más cercano. Es rápido y eficaz, aunque sensible a la elección del valor inicial de k y a la presencia de valores atípicos.

DBSCAN no requiere especificar el número de grupos a priori y detecta clústeres de cualquier forma, identificando además los datos considerados ruido. Su rendimiento es óptimo cuando se desea detectar anomalías o clústeres poco definidos.

Los **algoritmos jerárquicos** crean un árbol de agrupamiento basado en la similitud entre observaciones. Este método es ideal para visualizar estructuras internas de los datos mediante dendrogramas.

En la siguiente tabla se genera una comparativa de algoritmos de clustering.

Algoritmo	Necesita definir número de grupos	Manejo de ruido y outliers	Forma de los grupos	Velocidad
K-means	Sí	Sensible a outliers	Grupos esferoidales	Alta
DBSCAN	No	Detecta ruido	Grupos arbitrarios	Media
Jerárquico	No necesariamente	Puede incluir ruido	Estructura en árbol	Baja

Tabla 6: Comparativa de algoritmos de clustering

3.1.3 Aplicaciones en diferentes sectores

En **marketing digital**, el clustering se emplea para realizar **segmentación de clientes**. Por ejemplo, una tienda online como Decathlon puede agrupar

a sus usuarios según hábitos de compra, frecuencia de visitas y categorías preferidas, permitiendo ofrecer recomendaciones y promociones adaptadas.

En el ámbito **financiero**, entidades como ING utilizan clustering para identificar perfiles de comportamiento de los clientes y detectar patrones anómalos asociados a posibles fraudes. Esto reduce los riesgos operativos y permite adaptar productos a cada segmento.

En el sector **sanitario**, los hospitales pueden agrupar a los pacientes según síntomas y resultados de pruebas clínicas, facilitando el diagnóstico precoz de enfermedades y el diseño de tratamientos personalizados.

En el ámbito **educativo**, las plataformas de aprendizaje como Moodle aplican clustering para identificar patrones de participación y nivel de compromiso de los estudiantes, lo cual permite generar alertas tempranas y aplicar refuerzos adaptativos.

¿Sabías que?

Las aerolíneas aplican clustering para identificar tipos de viajeros y adaptar los menús, la atención y las promociones según si el perfil detectado es de negocio, vacacional o frecuente. Esta estrategia mejora la fidelidad sin aumentar el coste operativo.

3.2 Algoritmos: K-means, DBSCAN, PCA

El estudio de algoritmos de agrupamiento permite profundizar en las **herramientas clave del aprendizaje no supervisado**, especialmente en aquellos métodos diseñados para **descubrir estructuras ocultas** en los datos sin recurrir a etiquetas previas.

Entre los algoritmos más representativos se encuentran **K-means**, **DBSCAN** y **PCA (Análisis de Componentes Principales)**, cada uno con una lógica propia, distintas formas de interpretar la información y aplicaciones que los hacen útiles en contextos diversos.

3.2.1 K-means: partición de datos en clústeres de forma eficiente

K-means es uno de los algoritmos más conocidos por su sencillez y eficiencia en grandes conjuntos de datos. Su funcionamiento se basa en seleccionar un **número predefinido de clústeres** (k) y distribuir las observaciones en torno a centros (centroides) de forma iterativa.

Cada punto se asigna al centro más cercano en función de una métrica de distancia, y los centroides se recalculan tras cada iteración hasta lograr estabilidad.

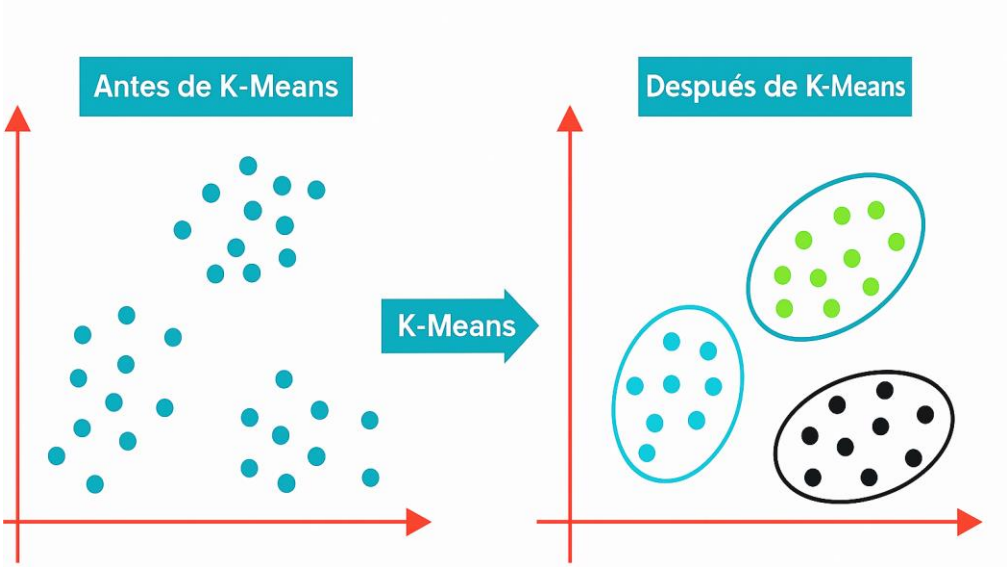

Figura 6: K-means

Ejemplo:

Un caso habitual en el que se aplica K-means es la segmentación de clientes en empresas de energía como Iberdrola. Agrupar a los usuarios según sus patrones de consumo permite ofrecer tarifas diferenciadas, prever picos de demanda y optimizar la generación.

Pese a su popularidad, presenta limitaciones. Requiere definir “k” antes de ejecutar el algoritmo, lo que no siempre es evidente. Además, sufre con outliers o clústeres de formas irregulares.

La selección del número óptimo de grupos puede abordarse con técnicas como el método del codo o el índice de silueta.

3.2.2 DBSCAN: detección de grupos de densidad variable

DBSCAN (Density-Based Spatial Clustering of Applications with Noise) fue desarrollado para superar algunas de las limitaciones de K-means. No requiere definir el número de clústeres y es eficaz en la detección de grupos de formas arbitrarias.

Se basa en la densidad de puntos: los que están próximos se consideran parte del mismo clúster, mientras que los puntos aislados se identifican como **ruido**.

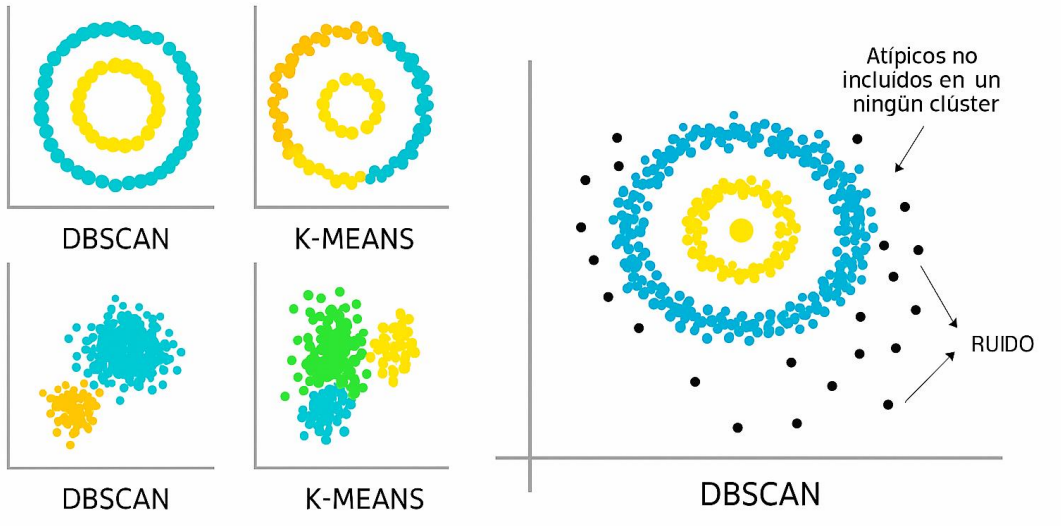

Figura 7: DBSCAN vs K-means

Este algoritmo se adapta muy bien al análisis de seguridad informática.

Por ejemplo, una empresa de ciberseguridad como S21sec puede utilizar DBSCAN para detectar accesos sospechosos en un sistema, ya que permite identificar patrones de comportamiento diferentes a los habituales.

DBSCAN requiere definir dos parámetros: épsilon (el radio de búsqueda) y minPts (el número mínimo de puntos para formar un grupo). Su rendimiento puede variar según la densidad del conjunto de datos y la elección de estos parámetros.

3.2.3 PCA: reducción de dimensionalidad y visualización

Aunque PCA (Principal Component Analysis) no es un algoritmo de clustering per se, se utiliza frecuentemente en combinación con otros métodos de agrupamiento. Su función es reducir la dimensionalidad de un conjunto de datos manteniendo la mayor cantidad posible de varianza. Esto se logra mediante la transformación lineal de las variables originales en nuevas componentes ortogonales.

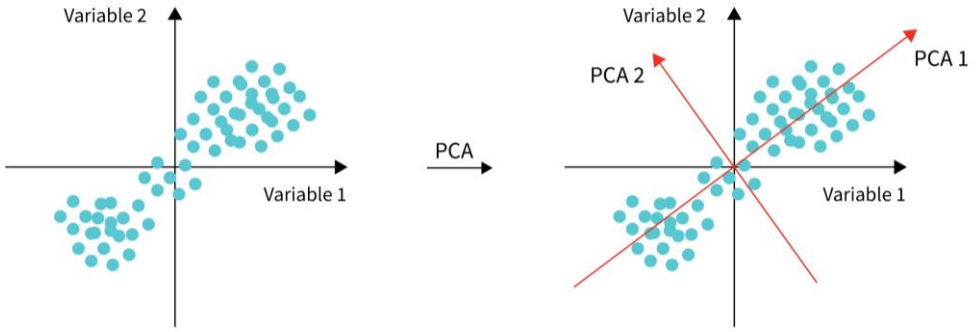

Figura 8: PCA

La utilidad de PCA es especialmente evidente en la visualización de datos de alta dimensionalidad.

Por ejemplo, en estudios genéticos, investigadores de centros como el CNIO aplican PCA para identificar patrones entre miles de genes y facilitar la posterior aplicación de K-means o DBSCAN.

Además de su valor visual, PCA mejora la eficiencia de los algoritmos posteriores, al eliminar redundancias y reducir el ruido. Sin embargo, esta transformación conlleva una pérdida de interpretabilidad, ya que las nuevas dimensiones no tienen un significado directo.

3.2.4 Comparativa de K-means, DBSCAN y PCA

A continuación, se presenta una tabla comparativa que sintetiza las características más relevantes de los algoritmos K-means, DBSCAN y PCA, tres técnicas clave en el análisis no supervisado.

Este esquema facilita la comprensión de sus diferencias en cuanto a requerimientos, comportamiento frente al ruido, tipo de agrupaciones que pueden detectar y principales aplicaciones.

Resulta especialmente útil para seleccionar el algoritmo más adecuado según la estructura de los datos y los objetivos del análisis.

Algoritmo	Requiere número de clústeres	Manejo de ruido	Tipo de grupos que detecta	Uso principal
K-means	Sí	Bajo	Grupos esferoidales	Agrupamiento rápido y eficaz
DBSCAN	No	Alto	Grupos de forma irregular	Detección de anomalías y ruido
PCA	No (complemen -tario)	N/A	Reduce dimensiones de cualquier tipo	Visualización y preprocesamien to de datos

Tabla 7: Comparativa de K-means, DBSCAN y PCA

¿Sabías que?

DBSCAN fue clave para mejorar el sistema de detección de sismos en Google. Gracias a su capacidad para identificar agrupamientos densos y separar el ruido, el sistema fue capaz de diferenciar con mayor precisión entre vibraciones reales y movimientos casuales del móvil.

Resumen

El Módulo 3 introduce los fundamentos del aprendizaje automático y su valor en entornos empresariales.

Se explican sus tres formas principales: el aprendizaje supervisado, que permite predecir resultados a partir de datos etiquetados; el no supervisado, que identifica patrones sin necesidad de etiquetas; y el aprendizaje por refuerzo, donde un agente aprende mediante la interacción con su entorno.

El módulo detalla cómo aplicar modelos de clasificación y regresión, utilizando algoritmos como árboles de decisión, regresión logística, SVM y k-NN. También se abordan técnicas de agrupamiento como K-means y DBSCAN, junto con métodos de reducción de dimensionalidad como PCA.

Además, se presenta el flujo de trabajo típico en un proyecto de machine learning, desde la definición del problema hasta la puesta en producción y monitorización del modelo. Se destacan tanto los beneficios, como la automatización y mejora en la toma de decisiones, como los retos asociados, incluyendo el sesgo de datos y la interpretabilidad de los modelos.

¡Esperamos que este resumen os haya sido útil!

www.awakelab.worl

MÓDULO 3:

Aprendizaje Automático (Machine Learning)

AWAKELAB | Desarrollado por Awakelab.world